



UNIVERSIDADE FEDERAL DE SÃO CARLOS

DEPARTAMENTO DE COMPUTAÇÃO

PROCESSAMENTO DE LINGUAGEM NATURAL

Deteccção Automática de Fake News em Português Brasileiro

DOCENTE RESPONSÁVEL: Helena Caseli

DISCENTES:

Bruno Nieri Nunes - 820590

Gabriel Lucchetta Garcia Sanchez - 828513

Gustavo Kim Alcantara - 820763

Pietro Bernardo Dutra Scaglione - 824375

Samuel Gerga Martins - 821772

Renato Dias Ferreira Campos - 821328

SÃO CARLOS – SP

Maio, 2026

1. Recapitulando Seminário 1

O Seminário 1 estruturou a proposta central do projeto: a detecção automática de fake news em português brasileiro. A base estabelecida para os experimentos foi o Fake.Br Corpus, um conjunto de dados perfeitamente balanceado composto por 7.200 documentos, divididos igualmente em 3.600 notícias falsas e 3.600 verdadeiras. O núcleo do planejamento baseou-se na investigação comparativa de três estratégias metodológicas com níveis crescentes de complexidade técnica.

A primeira estratégia visou a construção de um sistema interpretável baseado em regras heurísticas para capturar características estruturais, lexicais e ortográficas do texto, servindo como uma linha de base. A segunda estratégia propôs a vetorização clássica dos textos, utilizando técnicas como o TF-IDF, para treinar e alimentar algoritmos supervisionados de aprendizado de máquina, como Regressão Logística e SVM. Por último, a terceira estratégia previu a aplicação do BERTimbau, um modelo de linguagem baseado na arquitetura Transformer, para compreender as nuances semânticas mais profundas das notícias.

Para assegurar o rigor analítico, o plano definiu uma avaliação quantitativa utilizando métricas como Acurácia, Precisão, Recall e F1-score, aliada a uma profunda análise estrutural dos erros por meio de matrizes de confusão e verificações qualitativas.

2. Pré Processamento

A etapa de pré-processamento do *Fake.Br Corpus* foi conduzida com o objetivo de preparar uma base de dados centralizada que atendesse simultaneamente aos requisitos estruturais das três abordagens de classificação propostas neste trabalho. A ingestão de dados contemplou os 7.200 documentos originais em formato de texto plano (.txt). Para lidar com inconsistências de formatação nativas do corpus, desenvolveu-se uma heurística de extração que separou os títulos dos corpos das notícias, utilizando quebras de linha ou particionamento via expressões regulares (Regex) nos primeiros sinais de pontuação.

Para viabilizar a **Estratégia 1 (Sistema Baseado em Regras Heurísticas)**, realizou-se a engenharia de *features* sobre os textos em seu estado bruto. Foram extraídas variáveis quantitativas que indicam viés sensacionalista, incluindo a proporção de letras maiúsculas, a densidade de pontuações expressivas e a razão matemática entre o comprimento do título e o comprimento do corpo da notícia.

Em seguida, o pipeline de Processamento de Linguagem Natural (PLN) foi bifurcado para atender às particularidades dos modelos computacionais subsequentes. Para a **Estratégia 2 (Machine Learning com Representações Vetoriais)**, aplicou-se uma limpeza profunda utilizando a biblioteca *spaCy* (pt_core_news_sm). O texto foi convertido para minúsculas, expurgado de *stopwords*, e-mails, URLs e sinais de pontuação, finalizando com a lematização de todos os *tokens*, reduzindo assim a dimensionalidade para a futura vetorização

Por fim, para a **Estratégia 3 (Modelos de Linguagem baseados em Transformers - BERTimbau)**, executou-se uma limpeza estrutural leve. Removeu-se apenas o ruído de hiperlinks e caracteres de espaçamento redundantes. A pontuação, a capitalização e as *stopwords* foram rigorosamente preservadas, garantindo que a riqueza semântica e sintática do texto permanecesse intacta para a tokenização contextual via *WordPiece*. O resultado final foi consolidado em um conjunto de dados tabular unificado, assegurando o alinhamento das entradas para a posterior separação metodológica de treinamento, validação e teste.

3. Estratégias Investigadas

3.1 Estratégia 1: Sistema Baseado em Regras Heurísticas

3.1.1. Objetivo da Estratégia

A Estratégia 1 visou criar um sistema de detecção de Fake News baseado exclusivamente em regras pré-definidas (heurísticas), sem o uso de algoritmos de aprendizado de máquina. O foco foi identificar padrões linguísticos e estruturais que são frequentemente associados a notícias falsas.

3.1.2. Características Analisadas

O sistema foi construído para observar cinco pilares principais:

- Superficiais: Analisamos a proporção de letras maiúsculas (`pct_maiusculas`) e o uso excessivo de pontuação como ! e ? (`qtd_pontuacao_expressiva`).
- Lexicais (Clickbait): Criamos uma lista de termos sensacionalistas (ex: BOMBA, ABSURDO, REVELADO) e verificamos sua presença nos títulos.
- Estruturais: Calculamos a razão entre o tamanho do título e do corpo da notícia (`razao_titulo_corpo`).
- Credibilidade (Fontes): Verificamos se o texto mencionava fontes oficiais ou usava verbos de elocução (ex: afirmou, declarou, conforme). A ausência desses elementos aumentava a suspeita.

3.1.3. Implementação do Sistema de Pontuação

Desenvolvemos uma função que atribui pesos a cada uma dessas características:

- Cada regra satisfeita soma um valor ao `score_final` da notícia.
- Definimos um limiar (`threshold`): se o score atingir um determinado valor (atualmente 0.4), a notícia é classificada como Fake.

3.1.4. Ciclo de Refinamento

O desenvolvimento passou por iterações para melhorar a performance:

Ajuste de Sensibilidade: Inicialmente, o sistema era muito genérico. Refinamos os pesos para focar em Precisão, garantindo que as notícias marcadas como 'Fake' tivessem sinais muito claros.

Avaliação Separada: Isolamos o código de avaliação (Relatório de Classificação) da lógica do classificador para permitir testes rápidos de diferentes pesos.

3.1.5. Resultados Obtidos

Precisão de 0.77 para Fake News:

- Conseguimos um índice alto de acerto nas notícias que o sistema sinalizou, provando que as heurísticas de clickbait e falta de fontes são indicadores fortes.

Análise Qualitativa:

- O sistema identificou com score máximo (1.1) notícias que continham títulos alarmistas e falta de estrutura jornalística, validando a lógica aplicada.

Esta estratégia serve como uma excelente 'linha de base' (baseline) para compararmos com os modelos mais avançados que virão a seguir.

3.1.6. Desafios e Dificuldades da Estratégia 1

O Dilema da Precisão vs. Recall:

- Inicialmente, o sistema marcava muitas notícias reais como falsas (falsos positivos). Para resolver isso, aumentamos o rigor das regras (pesos e threshold). Isso nos deu uma excelente precisão (0.77), mas derrubou o recall (0.10). Ou seja: o sistema é ótimo para ter certeza do que é Fake, mas 'deixa passar' a grande maioria das notícias falsas mais sutis.

A 'Zona Cinzenta' dos Scores:

- Como vimos nos gráficos de KDE e Boxplot, há uma sobreposição enorme entre as classes. Muitas notícias reais usam exclamações ou títulos curtos, enquanto muitas fake news são escritas de forma polida e 'profissional', escapando totalmente de filtros baseados apenas em contagem de palavras ou maiúsculas.

Dependência de Regex (Expressões Regulares):

- Criar uma lista de termos de clickbait que cubra todas as variações sem gerar falsos positivos é um trabalho manual exaustivo e difícil de escalar.

Limitação Estrutural:

- Heurísticas não entendem o contexto ou o significado das palavras. Elas olham apenas para a 'forma'. Por isso, notícias falsas bem redigidas (estilo jornalístico clássico) são virtualmente invisíveis para este modelo.

- Essas dificuldades justificam perfeitamente o próximo passo: a Estratégia 2, onde o Machine Learning aprenderá a distinguir padrões estatísticos no texto que nós não conseguimos mapear manualmente.

3.2 Estratégia 2: Aprendizado de Máquina com Representações Vetoriais Clássicas

3.2.1. Objetivo e Metodologia

O foco desta etapa foi superar as limitações do sistema de regras (heurísticas) através de modelos que aprendem padrões estatísticos e semânticos. Utilizamos o dataset pré-processado, focando na coluna *texto_limpo_ml*.

3.2.2. Representação de Texto (Vetorização)

Técnica:

- Utilizamos o TF-IDF (Term Frequency-Inverse Document Frequency).

Granularidade:

- Configuramos `ngram_range=(1, 3)`, o que permitiu ao modelo analisar palavras isoladas, pares de palavras (bigramas) e trios (trigramas). Isso é crucial para capturar expressões como "Ministério Público" ou "segundo fontes", que indicam credibilidade ou falta dela.

Dimensionalidade:

- Limitamos o vocabulário em 5.000 features (termos mais relevantes) para evitar o overfitting e reduzir o custo computacional.

3.2.3. Experimento A: Abordagem Puramente Textual

Treinamos três modelos clássicos usando apenas a matriz esparsa gerada pelo TF-IDF:

Multinomial Naive Bayes:

- Resultado:
 - F1-Score de 0.86.
- Análise:
 - Foi um modelo rápido e eficaz para texto, mas tende a ser simplista por assumir independência total entre as palavras.

Logistic Regression (Otimizada):

- Resultado:
 - Acurácia de 96% (com parâmetro de regularização C=10).
- Análise:
 - Demonstrou ser extremamente poderosa para separar as classes linearmente no espaço vetorial de alta dimensão.

SVM (Support Vector Machine):

- Resultado:
 - Acurácia de 95% (kernel rbf).
- Análise:
 - Similar à regressão logística, confirmando que os padrões textuais do dataset são bem definidos.

3.2.4. Experimento B: Abordagem Híbrida (Texto + Heurísticas)

A inovação deste experimento foi a concatenação de dados heterogêneos. Unimos os 5.000 atributos de texto com 4 atributos numéricos da Estratégia 1 (pct_maiusculas, qtd_pontuacao_expressiva, razao_titulo_corpo, comprimento_texto).

Regressão Logística Híbrida:

- Resultado:
 - Elevou a acurácia para 97%.
- Recall para Fake News (Classe 1):
 - Atingiu 0.98, corrigindo a maior falha da Estratégia 1 (que era de apenas 0.10).

XGBoost Híbrido:

- Resultado:
 - Acurácia de 96%.
- Análise:
 - Embora seja um modelo de árvores de decisão complexo, a regressão logística performou ligeiramente melhor devido à natureza esparsa dos dados TF-IDF.

3.2.5. Conclusão da Estratégia

Os modelos clássicos de Machine Learning, quando combinados com atributos estruturais, mostraram-se quase perfeitos para este dataset específico. A precisão saltou de 77% (heurística óbvia) para 97% (ML Híbrido), provando que a união entre o contexto das palavras e os sinais de sensacionalismo é o caminho mais eficaz antes de partirmos para modelos de Deep Learning.

3.3 Estratégia 3: Modelos de Linguagem Baseados em

Transformers (BERTimbau)

3.3.1. Objetivo da Estratégia

A Estratégia 3 teve como objetivo investigar o uso de um modelo de linguagem baseado em *Transformers* para a classificação de fake news em português brasileiro. Diferentemente das abordagens anteriores, que dependem de regras manuais ou de representações vetoriais mais superficiais, esta estratégia busca explorar o contexto semântico completo das notícias, considerando a relação entre palavras, a ordem dos termos e os padrões linguísticos aprendidos durante o pré-treinamento.

O modelo escolhido foi o **BERTimbau** (*neuralmind/bert-base-portuguese-cased*), por ser uma alternativa pré-treinada especificamente para o português e amplamente utilizada em tarefas de PLN no idioma. A hipótese central dessa estratégia é que um modelo contextualizado pode capturar nuances linguísticas que passam despercebidas pelas heurísticas e pelo TF-IDF, melhorando a capacidade de generalização diante de textos mais sutis e menos sensacionalistas.

3.3.2. Representação do Texto e Pré-processamento

Para essa estratégia, foi utilizada a coluna *texto_limpo_bert*, construída para preservar características importantes para o modelo contextual. Ao contrário da versão destinada ao Machine Learning clássico, aqui não se removeu pontuação, capitalização nem *stopwords*, pois esses elementos podem contribuir para o entendimento do contexto pelo tokenizador WordPiece e pela camada de atenção do BERT.

O pré-processamento aplicado foi propositalmente leve, restringindo-se à remoção de ruídos estruturais, como links e espaçamentos redundantes. A ideia foi manter o texto o mais próximo possível da sua forma original, para que o modelo pudesse explorar sinais semânticos e sintáticos de forma mais rica.

3.3.3. Arquitetura e Configuração do Modelo

A implementação foi feita por meio da biblioteca *transformers*, com o carregamento do modelo *BertForSequenceClassification* a partir do checkpoint do BERTimbau cased. Como a tarefa é binária, a cabeça de classificação foi adaptada para duas saídas: *fake* e *verdadeira*.

O fluxo de treinamento adotado no notebook foi o seguinte:

- divisão estratificada dos dados em treino, validação e teste na proporção 70/10/20;
- tokenização com *AutoTokenizer* preservando a estrutura original do texto;
- truncamento e *padding* até o limite máximo de 512 tokens;
- treinamento supervisionado com *Trainer*;
- uso de *early stopping* para evitar *overfitting*;
- seleção do melhor modelo com base no F1-score da validação.

Os hiperparâmetros utilizados foram ajustados para um cenário realista de fine-tuning: taxa de aprendizado baixa, poucas épocas e *batch size* reduzido, já que o treinamento completo de BERT exige maior capacidade computacional e, idealmente, o uso de GPU.

3.3.4. Implementação e Ciclo de Treinamento

A implementação da estratégia foi organizada em três blocos principais no notebook. Primeiro, realizou-se a preparação do conjunto de dados com a coluna *texto_limpo_bert* e a criação de uma classe *Dataset* personalizada para alimentar o modelo. Em seguida, o BERTimbau foi carregado e configurado para a tarefa de classificação.

Depois disso, o treinamento foi conduzido com *TrainingArguments*, incorporando validação por época, salvamento do melhor checkpoint e monitoramento do F1-score. A execução do treinamento é a etapa mais custosa dessa estratégia e, por isso, foi pensada para ambientes com aceleração por GPU, como Google Colab ou Kaggle.

3.3.5. Avaliação da Estratégia

A Estratégia 3 foi avaliada com base no comportamento do *fine-tuning* ao longo das épocas e no desempenho final sobre o conjunto de teste. O treinamento apresentou convergência rápida e estável: a *training loss* caiu de 0.147247 na primeira época para 0.004503 na terceira, enquanto a *validation loss* permaneceu baixa, variando entre 0.036146 e 0.081740. Esse padrão indica que o modelo aprendeu rapidamente a separar as classes sem apresentar sinais relevantes de instabilidade durante o ajuste.

Nas métricas de validação por época, o BERTimbau obteve os seguintes resultados:

- Época 1: *accuracy* de 0.990278, *precision* de 0.986226, *recall* de 0.994444 e

F1-score de 0.990318.

- Época 2: *accuracy* de 0.987500, *precision* de 0.980822, *recall* de 0.994444 e *F1-score* de 0.987586.
- Época 3: *accuracy* de 0.991667, *precision* de 0.986264, *recall* de 0.997222 e *F1-score* de 0.991713.

No conjunto de teste, o modelo atingiu *accuracy* de 0.9944, com *macro avg* de 0.9944 para *precision*, *recall* e *F1-score*. A matriz de confusão mostrou apenas 8 erros no total: 715 notícias verdadeiras foram corretamente classificadas como verdadeiras, 717 fake news foram corretamente classificadas como fake, com 5 falsos positivos e 3 falsos negativos. Além disso, o *AUC-ROC* alcançou 0.9991, sugerindo uma separação praticamente perfeita entre as classes.

Esses resultados confirmam que o BERTimbau foi capaz de capturar padrões contextuais do corpus de forma muito mais precisa do que as abordagens anteriores, especialmente em casos em que a detecção depende da combinação entre semântica, estrutura sintática e sinais discursivos mais sutis.

3.3.6. Desafios e Dificuldades da Estratégia 3

O principal desafio dessa estratégia foi o custo computacional. O *fine-tuning* do BERTimbau exige GPU, mais memória e maior tempo de execução do que os modelos anteriores, sobretudo por trabalhar com sequências longas e por atualizar uma arquitetura com grande quantidade de parâmetros. Mesmo assim, o treinamento se mostrou eficiente no ambiente utilizado, com convergência em poucas épocas e resultado final muito elevado.

Outro ponto importante foi a necessidade de preservar capitalização, pontuação e *stopwords* no texto de entrada. Essa escolha aumenta a riqueza informacional, mas também exige mais cuidado na preparação dos dados, porque o desempenho do modelo depende do texto manter o formato contextual que foi previsto na sua pré-treinação.

3.3.7. Conclusão da Estratégia

A Estratégia 3 confirmou que modelos baseados em *Transformers* são altamente eficazes para a detecção automática de fake news em português brasileiro. Enquanto a Estratégia 1 depende de sinais superficiais e a Estratégia 2 aprende padrões estatísticos no espaço vetorial, o BERTimbau conseguiu integrar contexto, semântica e estrutura

textual de forma muito mais robusta.

Na prática, os resultados mostraram uma diferença clara em relação às abordagens anteriores: o modelo alcançou *accuracy* de 0.9944 e *F1-score* de 0.9944 no teste, com apenas 8 erros em 1440 exemplos e *AUC-ROC* de 0.9991. Isso indica que, para o Fake.Br Corpus, o uso de BERTimbau oferece o melhor equilíbrio entre sensibilidade e especificidade entre as estratégias avaliadas.

Apesar do maior custo computacional, a Estratégia 3 se destacou como a melhor solução do trabalho em termos de desempenho, reforçando o valor de modelos pré-treinados para tarefas de classificação textual em português.

4. Avaliação da Tarefa

Nesta seção, avaliamos o desempenho das três estratégias implementadas para a detecção de fake news no Fake.Br Corpus. A análise foca na capacidade de generalização de cada abordagem e nos erros sistemáticos observados durante a auditoria.

4.1. Análise Comparativa de Desempenho

Os resultados demonstram uma evolução clara na métrica F1-Score à medida que aumentamos a complexidade do processamento de linguagem natural:

Estratégia 1 (Heurísticas): Atuou como um baseline de baixa complexidade. Embora tenha identificado com sucesso notícias sensacionalistas (alto uso de exclamações e caps lock), apresentou baixa revocação, pois muitas notícias falsas modernas adotam uma linguagem formal para mimetizar a imprensa tradicional.

Estratégia 2 (ML Clássico e Híbrido): A utilização de TF-IDF com N-gramas (1-3) mostrou-se extremamente robusta. O modelo de Regressão Logística Híbrida, que combinou o vetor de texto com os atributos numéricos da Estratégia 1, apresentou o melhor equilíbrio entre tempo de processamento e precisão, superando o Naive Bayes.

Estratégia 3 (BERTimbau): O modelo Transformer obteve a maior performance global. Sua capacidade de processar o contexto bidirecional permitiu identificar nuances semânticas e sarcasmo que os modelos baseados em frequência de palavras (TF-IDF) ignoram.

4.2. Auditoria de Erros e Casos Notáveis

A auditoria qualitativa revelou padrões importantes:

Falsos Positivos: Notícias verdadeiras curtas ou com citações muito informais foram ocasionalmente classificadas como falsas devido à ausência de estruturas típicas de reportagens longas.

Falsos Negativos: Notícias falsas que replicam perfeitamente a estrutura de um portal de notícias (sem erros gramaticais ou sensacionalismo visual) foram os casos mais desafiadores, exigindo o poder de processamento do BERT para detecção.

4.3. Conclusão da Avaliação

O Coeficiente Kappa obtido entre as regras manuais e o modelo BERT indica uma concordância moderada, o que sugere que, embora os sinais superficiais (heurísticas) sejam úteis, eles não são suficientes para o cenário de desinformação atual. Para um sistema em produção, a Estratégia 2 (Híbrida) é recomendada pelo baixo custo operacional, enquanto a Estratégia 3 é ideal para cenários onde a precisão máxima é inegociável.

5. Considerações Finais

O desenvolvimento e a execução das três estratégias evidenciaram uma progressão metodológica clara na capacidade de identificar desinformação dentro do corpus estudado. A Estratégia 1 cumpriu seu papel inicial ao validar a utilidade de sinais sensacionalistas e falhas estruturais, atingindo uma precisão de 0.77. No entanto, sua dependência estrutural resultou em uma severa limitação de recall (0.10), demonstrando que sistemas baseados exclusivamente em heurísticas falham criticamente ao analisar fake news redigidas de forma polida e com simulação de um formato jornalístico tradicional. A adoção de aprendizado de máquina na Estratégia 2 mitigou essas deficiências de forma substancial. O destaque dessa etapa foi a modelagem híbrida que concatenou representações vetoriais textuais (TF-IDF) aos atributos numéricos calculados na primeira fase, elevando a acurácia geral para 97% e disparando o recall da classe falsa para 0.98.

Porém, a Estratégia 3 estabeleceu-se como a solução definitiva e de maior robustez. O fine-tuning do BERTimbau integrou contexto, semântica e estrutura de maneira primorosa, alcançando uma acurácia e F1-score quase irretocáveis de 0.9944. A análise da matriz de confusão reforçou esse patamar de excelência, registrando ínfimos 8 erros sobre todo o conjunto de teste de 1.440 amostras. Conclui-se que, a despeito do alto custo computacional,

do longo tempo de execução e da necessidade de infraestrutura com GPU, as arquiteturas baseadas em Transformers oferecem o melhor desempenho global e o equilíbrio ideal entre sensibilidade e especificidade, atestando seu valor indispensável para o avanço das tarefas de classificação textual no português brasileiro.

6. Referências

Estratégias que serão investigadas:

- [A Survey on Natural Language Processing for Fake News Detection](<https://aclanthology.org/2020.lrec-1.747/>) (Oshikawa et al., LREC 2020) <https://aclanthology.org/2020.lrec-1.747/>
- SPARCK JONES K (1972), "A STATISTICAL INTERPRETATION OF TERM SPECIFICITY AND ITS APPLICATION IN RETRIEVAL". *Journal of Documentation*, Vol. 28 No. 1 pp. 11–21, doi: <https://doi.org/10.1108/eb026526>
- Piotr Bojanowski, Edouard Grave, Armand Joulin, Tomas Mikolov; Enriching Word Vectors with Subword Information. *Transactions of the Association for Computational Linguistics* 2017; 5 135–146. doi: https://doi.org/10.1162/tac1_a_00051
- Bojanowski, P., Grave, E., Joulin, A., & Mikolov, T. (2017). *Enriching Word Vectors with Subword Information*. *Transactions of the Association for Computational Linguistics*, 5, 135–146. https://doi.org/10.1162/tac1_a_00051
- Vieira, A. C. et al. (2023). *fakenewsbr: A Fake News Detection Platform for Brazilian Portuguese*. arXiv:2309.11052. <https://arxiv.org/abs/2309.11052>
- Souza, F., Nogueira, R., Lotufo, R. (2020). BERTimbau: Pretrained BERT Models for Brazilian Portuguese. In: Cerri, R., Prati, R.C. (eds) *Intelligent Systems. BRACIS 2020. Lecture Notes in Computer Science()*, vol 12319. Springer, Cham. https://doi.org/10.1007/978-3-030-61377-8_28

Métodos de Avaliação:

- Kohavi, R. (1995). *A Study of Cross-Validation and Bootstrap for Accuracy Estimation and Model Selection*. In: *Proceedings of the 14th International Joint Conference on Artificial Intelligence (IJCAI 1995)*, Montreal, pp. 1137–1145. <https://www.ijcai.org/Proceedings/95-2/Papers/016.pdf>
- Manning, C. D., Raghavan, P., & Schütze, H. (2008). *Introduction to Information Retrieval*. Cambridge University Press. Disponível em: <https://nlp.stanford.edu/IR-book/>
- Silva, R. M., Santos, R. L. S., Almeida, T. A., & Pardo, T. A. S. (2020). *Towards automatically filtering fake news in Portuguese*. *Expert Systems with Applications*, 146, 113199. <https://doi.org/10.1016/j.eswa.2020.113199>
- Cohen, J. (1960). *A coefficient of agreement for nominal scales*. *Educational and Psychological Measurement*, 20(1), 37–46. <https://doi.org/10.1177/001316446002000104>
- Landis JR, Koch GG. The measurement of observer agreement for categorical data. *Biometrics*. 1977 Mar;33(1):159-74. PMID: 843571. <https://pubmed.ncbi.nlm.nih.gov/843571/>

